

文本分类

陈冠毅

g.chen@ccnu.edu.cn

计算机学院
华中师范大学

Overview

基本概念

生成模型

结果评价

判别模型


特征选择

使用大语言模型进行文本分类


解决问题的方式：分类




解决问题的方式：分类 Cont.




解决问题的方式：回归



解决问题的方式：聚类



解决问题的方式：排序



Cao, Zhe, et al. "Learning to rank: from pairwise approach to listwise approach."

<https://embracingtherandom.com/machine-learning/tensorflow/ranking/deep-learning/learning-to-rank-part-2/>

这节课+实验：文本分类



My experience
so far has been
fantastic!

POSITIVE



The product is
ok I guess

NEUTRAL



Your support team
is useless

NEGATIVE

文本分类的形式化定义

给定

1. 文本 $d \in \mathbb{X}$, 其中 $\mathbb{X}$ 是文本空间;
2. 分类目标类的集合 $\mathbb{C} = \{c_1, c_2, \dots, c_j\}$;
3. 训练数据 $\mathbb{D}$: $\mathbb{D}$ 含有形如 $\langle d, c \rangle$ 的元素 $\langle d, c \rangle \in \mathbb{X} \times \mathbb{C}$, 比如:
 $\langle d, c \rangle = \langle \text{Beijing joints the WHO, China} \rangle$

任务是训练一个分类器或一个分类函数 γ , 将文档映射到类:

$$\gamma: \mathbb{X} \rightarrow \mathbb{C}$$

两种建模机制

- **判别模型**: 直接估计 $P(c|d)$ 。
例如: 逻辑回归, K近邻算法等。
- **生成模型**: 估计联合概率分布 $P(d, c)$ 并利用结果推断 $P(c|d)$ 。
例如: 朴素贝叶斯, 判别分析。

两种建模机制

- **判别模型**: 直接估计 $P(c|d)$ 。
例如: 逻辑回归, K近邻算法等。
- **生成模型**: 估计联合概率分布 $P(d, c)$ 并利用结果推断 $P(c|d)$ 。
例如: 朴素贝叶斯, 判别分析。

Overview

基本概念

生成模型

结果评价

判别模型

特征选择

使用大语言模型进行文本分类

生成模型：以掷硬币为例

- 假设有一个硬币，掷了十次，获得了观察： $d = \text{HTTTHTHTT}$
- 硬币应该是一个什么样子？
- 假设：
 1. 模型1: 硬币是均匀的, $\hat{P}(H) = 0.5$
 2. 模型2: 硬币是不均匀的, $\hat{P}(H) = 0.7$
 3. 模型3: 硬币是不均匀的, $\hat{P}(H) = 0.6$
 4. ...

生成模型：以掷硬币为例

- 假设有一个硬币，掷了十次，获得了观察： $d = \text{HTTTHTHTT}$
- 硬币应该是一个什么样子？
- 假设：
 1. 模型1: 硬币是均匀的, $\hat{P}(H) = 0.5$
 2. 模型2: 硬币是不均匀的, $\hat{P}(H) = 0.7$
 3. 模型3: 硬币是不均匀的, $\hat{P}(H) = 0.6$
 4. ...

生成模型：以掷硬币为例

- 假设有一个硬币，掷了十次，获得了观察： $d = \text{HTTTHTHTT}$
- 硬币应该是一个什么样子？
- 假设：
 1. 模型1: 硬币是均匀的, $\hat{P}(H) = 0.5$
 2. 模型2: 硬币是不均匀的, $\hat{P}(H) = 0.7$
 3. 模型3: 硬币是不均匀的, $\hat{P}(H) = 0.6$
 4. ...

生成模型：以掷硬币为例

- 假设有一个硬币，掷了十次，获得了观察： $d = \text{HTTTHTHTT}$
- 硬币应该是一个什么样子？
- 假设：
 1. 模型1: 硬币是均匀的, $\hat{P}(H) = 0.5$
 2. 模型2: 硬币是不均匀的, $\hat{P}(H) = 0.7$
 3. 模型3: 硬币是不均匀的, $\hat{P}(H) = 0.6$
 4. ...

每一个模型都可以看做是观察的一个生成过程。这种模型叫做生成模型，描述了数据生成的过程：

1. 从硬币模型的概率分布 $P(\theta)$ 中选择一个硬币的模型 θ ;
2. 每一个观测都可以看做是从 $P(d|\theta)$ 这个分布进行采样得到的, d_i 的值可以是H或T。

对于文本分类来说

文本中词可以看做是通过如下方式产生的：

1. 从类别的分布中 $P(c)$ 选择一个类别。
2. 从条件概率分布 $P(t|c)$ 对词采样进行采样。

因此，文本分类的生成模型可以定义成如下形式：

为了从输入文档 d 中预测其类别 C ，我们需要计算 $P(C|d)$.

因此，文本分类的生成模型可以定义成如下形式：

为了从输入文档 d 中预测其类别 C ，我们需要计算 $P(C|d)$ 。

利用贝叶斯公式：

$$P(C = c|d) = \frac{P(d, c)}{P(d)} = \frac{P(d|c)P(c)}{P(d)} = \frac{P(d|c)P(c)}{\sum_{c' \in \mathbb{C}} P(d|c')P(c')}$$

因此，文本分类的生成模型可以定义成如下形式：

为了从输入文档 d 中预测其类别 C ，我们需要计算 $P(C|d)$ 。

利用贝叶斯公式：

$$P(C = c|d) = \frac{P(d, c)}{P(d)} = \frac{P(d|c)P(c)}{P(d)} = \frac{P(d|c)P(c)}{\sum_{c' \in \mathbb{C}} P(d|c')P(c')}$$

能够最大化该后验概率的类别 c_{map} 即为给定文档 d 的最佳类别 $\hat{c}$ ：

$$c_{map} = \arg \max_{c \in \mathbb{C}} P(c|d)$$

关于 $P(c)$

假设有大小是 N 的训练集 $\mathbb{D}$:

$$\mathbb{D} = \{(d_1, c_1), \dots, (d_N, c_N)\}$$

利用最大似然估计:

$$\hat{P}(c) = \frac{N_c}{N}, \quad (1)$$

即类别是 c 的数据在训练集中的比例。

关于 $P(d|c)$

$P(d|c)$ 不是 $P(w|c)$!

关于 $P(d|c)$

$P(d|c)$ 不是 $P(w|c)$!

假设文档中含有 M 个单词并且 $d = (w_1, w_2, \dots, w_M)$ 是一个布尔向量。

关于 $P(d|c)$

$P(d|c)$ 不是 $P(w|c)$!

假设文档中含有 M 个单词并且 $d = (w_1, w_2, \dots, w_M)$ 是一个布尔向量。

为了估计 $P(d|c)$, 我们需要计算所有可能的 d .

那么对于每一个类, 我们需要进行多少次计算?

关于 $P(d|c)$

$P(d|c)$ 不是 $P(w|c)$!

假设文档中含有 M 个单词并且 $d = (w_1, w_2, \dots, w_M)$ 是一个布尔向量。

为了估计 $P(d|c)$, 我们需要计算所有可能的 d .

那么对于每一个类, 我们需要进行多少次计算?

$$2^M$$

关于 $P(d|c)$

$P(d|c)$ 不是 $P(w|c)$!

假设文档中含有 M 个单词并且 $d = (w_1, w_2, \dots, w_M)$ 是一个布尔向量。

为了估计 $P(d|c)$, 我们需要计算所有可能的 d .

那么对于每一个类, 我们需要进行多少次计算?

$$2^M$$

当 $M = 30$ 时, 我们就已经需要计算超过10亿个概率!这种现象被称为维度爆炸。

朴素贝叶斯假设

假设在同一类别下，所有特征之间都互相独立

那么，我们就可以得到：

$$P(d|c) = P(w_1|c) \cdot P(w_2|c) \cdots P(w_M|c) = \prod_{i=1}^M P(w_i|c)$$

对于每个类别，我们只需要计算 $M = 30$ 个不同的概率！

朴素贝叶斯假设

假设在同一类别下，所有特征之间都互相独立

那么，我们就可以得到：

$$P(d|c) = P(w_1|c) \cdot P(w_2|c) \cdots P(w_M|c) = \prod_{i=1}^M P(w_i|c)$$

对于每个类别，我们只需要计算 $M = 30$ 个不同的概率！

朴素贝叶斯分类器

$$P(C = c|d) = \frac{\prod_{i=1}^M P(w_i|c)P(c)}{\sum_{c' \in \mathbb{C}} \prod_{i=1}^M P(w_i|c')P(c')}$$

朴素贝叶斯分类器

$$P(C = c|d) = \frac{\prod_{i=1}^M P(w_i|c)P(c)}{\sum_{c' \in \mathbb{C}} \prod_{i=1}^M P(w_i|c')P(c')}$$

找到最优的类别等价于:

$$c_{\text{NB}}(d) = \arg \max_{c \in \mathbb{C}} P(c) \prod_{i=1}^M P(w_i|c)$$

$P(w_i|c)$ 的最大似然估计是:

$$\hat{P}(w_i|c) = \frac{\hat{P}(w_i, c)}{\hat{P}(c)} = \frac{N_{w_i, c}/N}{N_c/N} = \frac{N_{w_i, c}}{N_c},$$

其中 $N_{w_i, c}$ 表示含有 $W_i = w_i$ 并且类别是 $C = c$ 文档数量。

$P(w_i|c)$ 的最大似然估计是:

$$\hat{P}(w_i|c) = \frac{\hat{P}(w_i, c)}{\hat{P}(c)} = \frac{N_{w_i, c}/N}{N_c/N} = \frac{N_{w_i, c}}{N_c},$$

其中 $N_{w_i, c}$ 表示含有 $W_i = w_i$ 并且类别是 $C = c$ 文档数量。

但是, $P(w_i|c)$ 可以是0.

拉普拉斯平滑

拉普拉斯平滑被用来避免0概率:

$$\hat{P}(w_i|c) = \frac{N_{w_i,c} + 1}{\sum_{w'_i \in \mathbb{W}_i} N_{w'_i,c} + 1} = \frac{N_{w_i,c} + 1}{N_c + |\mathbb{W}_i|},$$

其中 $|\mathbb{W}_i|$ 表示 $\mathbb{W}_i$ 可选择值的大小, 即为2。

例子

	docID	words in document	$c = \text{China?}$
training set	1	Chinese Beijing Chinese	yes
	2	Chinese Chinese Shanghai	yes
	3	Chinese Macao	yes
	4	Tokyo Japan Chinese	no
test set	5	Chinese Chinese Chinese Tokyo Japan	?

例子

伯努利模型:

docID	Chinese	Beijing	Shanghai	Macao	Tokyo	Japan	Topic = China?
1	1	1	0	0	0	0	yes
2	1	0	1	0	0	0	yes
3	1	0	0	1	0	0	yes
4	1	0	0	0	1	1	no
5	1	0	0	0	1	1	?

只记录每个词是否出现。

例子

符号: c = 关于China; $\bar{c}$ = 不关于China

$\hat{P}(\text{Chinese}|c)$ 为 $\hat{P}(\text{Chinese} = 1|c)$ 的简化形式, etc.

参数估计(拉普拉斯平滑):

$$\hat{P}(\text{Chinese}|c) = (3 + 1)/(3 + 2) = 4/5$$

$$\hat{P}(\text{Japan}|c) = \hat{P}(\text{Tokyo}|c) = (0 + 1)/(3 + 2) = 1/5$$

$$\hat{P}(\text{Beijing}|c) = \hat{P}(\text{Macao}|c) = \hat{P}(\text{Shanghai}|c) = (1 + 1)/(3 + 2) = 2/5$$

$$\hat{P}(\text{Chinese}|\bar{c}) = (1 + 1)/(1 + 2) = 2/3$$

$$\hat{P}(\text{Japan}|\bar{c}) = \hat{P}(\text{Tokyo}|\bar{c}) = (1 + 1)/(1 + 2) = 2/3$$

$$\hat{P}(\text{Beijing}|\bar{c}) = \hat{P}(\text{Macao}|\bar{c}) = \hat{P}(\text{Shanghai}|\bar{c}) = (0 + 1)/(1 + 2) = 1/3$$

所以, $\hat{P}(c) = \frac{3}{4}$ 并且 $\hat{P}(\bar{c}) = \frac{1}{4}$.

例子

所以朴素贝叶斯模型对于文档5的预测是：

$$\begin{aligned}\hat{P}(c|(1, 0, 0, 0, 1, 1)) &\propto \hat{P}(c) \cdot \hat{P}(Chinese|c) \cdot (1 - \hat{P}(Beijing|c)) \\ &\quad \cdot (1 - \hat{P}(Shanghai|c)) \cdot (1 - \hat{P}(Macao|c)) \\ &\quad \cdot \hat{P}(Tokyo|c) \cdot \hat{P}(Japan|c) \\ &= 3/4 \cdot 4/5 \cdot 3/5 \cdot 3/5 \cdot 3/5 \cdot 1/5 \cdot 1/5 \approx 0.005\end{aligned}$$

相似地

$$\hat{P}(\bar{c} |(1, 0, 0, 0, 1, 1)) \propto 1/4 \cdot (2/3)^6 \approx 0.022$$

因此，文档5不是有关China的文档。

Questions?

朴素贝叶斯: 多项式分布版

在多项式模型中, 我们假设:

$$P(c|d) \propto P(c) \prod_{k=1}^{n_d} P(t_k|c),$$

其中, $d = \langle t_1, \dots, t_{n_d} \rangle$, t_k 是 d 文档中的第 k 个词, $P(t_k|c)$ 是 t_k 在 c 这个类的文档中在任何位置出现的条件概率, n_d 是 d 中词的数量。

对于词典中的所有词 $t \in V$, 我们可以估计 $P(t|c)$:

$$\hat{P}(t|c) = \frac{T_{ct}}{\sum_{t' \in V} T_{ct'}}$$

其中, T_{ct} 是 t 在属于 c 类的训练数据中出现的频率, V 是字典。

多项式模型: 平滑方法

$$\hat{P}(t|c) = \frac{T_{ct} + 1}{\sum_{t' \in V} (T_{ct'} + 1)} = \frac{T_{ct} + 1}{\sum_{t' \in V} T_{ct'} + |V|}$$

$|V|$ 是字典的大小。

例子

多项式模型:

docID	Chinese	Beijing	Shanghai	Macao	Tokyo	Japan	Topic = China?
1	2	1	0	0	0	0	yes
2	2	0	1	0	0	0	yes
3	1	0	0	1	0	0	yes
4	1	0	0	0	1	1	no
5	3	0	0	0	1	1	?

多项式模型: 参数估计

$$\hat{P}(\textit{Chinese}|c) = (5 + 1)/(8 + 6) = 3/7$$

$$\hat{P}(\textit{Japan}|c) = \hat{P}(\textit{Tokyo}|c) = (0 + 1)/(8 + 6) = 1/14$$

$$\hat{P}(\textit{Beijing}|c) = \hat{P}(\textit{Macao}|c) = \hat{P}(\textit{Shanghai}|c) = (1 + 1)/(8 + 6) = 1/7$$

$$\hat{P}(\textit{Chinese}|\bar{c}) = (1 + 1)/(3 + 6) = 2/9$$

$$\hat{P}(\textit{Japan}|\bar{c}) = \hat{P}(\textit{Tokyo}|\bar{c}) = (1 + 1)/(3 + 6) = 2/9$$

$$\hat{P}(\textit{Beijing}|\bar{c}) = \hat{P}(\textit{Macao}|\bar{c}) = \hat{P}(\textit{Shanghai}|\bar{c}) = (0 + 1)/(3 + 6) = 1/9$$

所以, $\hat{P}(c) = \frac{3}{4}$, $\hat{P}(\bar{c}) = \frac{1}{4}$.

多项式模型: 预测

多项式朴素贝叶斯模型对5号文本的预测:

$$\hat{P}(c|d_5) \propto 3/4 \cdot (3/7)^3 \cdot 1/14 \cdot 1/14 \approx 0.0003$$

$$\hat{P}(\bar{c}|d_5) \propto 1/4 \cdot (2/9)^3 \cdot 2/9 \cdot 2/9 \approx 0.0001$$

它是有关China的文本。

Overview

基本概念

生成模型

结果评价

判别模型


特征选择

使用大语言模型进行文本分类

准确率、精确率、召回率

预测值/真实值	是类别A	不是类别A
是类别A	true positives (TP)	false positives (FP)
不是类别A	false negatives (FN)	true negatives (TN)

Docs about China



- China classified as China
- Not China classified as China

准确率、精确率、召回率

预测值/真实值	是类别A	不是类别A
是类别A	true positives (TP)	false positives (FP)
不是类别A	false negatives (FN)	true negatives (TN)

- 真确率是正确预测的比例:

$$\text{Accuracy} = \frac{TP + TN}{N_{\text{test}}}$$

- 精确率:

$$P = TP / (TP + FP)$$

- 召回率:

$$R = TP / (TP + FN)$$

准确率、精确率、召回率

预测值/真实值	是类别A	不是类别A
是类别A	true positives (TP)	false positives (FP)
不是类别A	false negatives (FN)	true negatives (TN)

- 真确率是正确预测的比例:

$$\text{Accuracy} = \frac{TP + TN}{N_{\text{test}}}$$

- 精确率:


$$P = TP / (TP + FP)$$

- 召回率:

$$R = TP / (TP + FN)$$

准确率、精确率、召回率

Docs about China



 - China classified as China

 - Not China classified as China

$$\text{precision} = \frac{\text{TP}}{\text{TP} + \text{FP}}$$

$$\text{recall} = \frac{\text{TP}}{\text{TP} + \text{FN}}$$

- 精确率: 有多说被识别出的与China相关的文本是正确的?
- 召回率: 有多说被识别出的与China相关的文本被识别出来了?

精确率和召回率的融合: F 分数

F_1 平衡了精确率和召回率，是它们的调和平均数

$$F_1 = \frac{2P \times R}{P + R}$$

Micro F1 vs. Macro F1

- 上述F1的计算方法只是对于一个类而言的。
- 当进行多分类时，有以下两种方法：
- **Macro F1**
 - 对每个类别都计算一个 F_1
 - 计算它们的平均数
- **Micro F1**
 - 对每个类别计算TP, FP, FN
 - 对所有类的TP, FP, FN求和
 - 计算 F_1

Overview

基本概念

生成模型




结果评价

判别模型

特征选择

使用大语言模型进行文本分类

信用卡额度



我们能不能利用线性规划直接对 $P(c|d)$ 进行建模?

假设这个分类任务可以被定义成:

$$Y = \begin{cases} 0 & \text{if No} \\ 1 & \text{if Yes} \end{cases}$$

我们能不能拟合一个线性规划用 X 来预测 Y ，并且根据 $\hat{y} > 0.5$ 来进行分类?

我们能不能利用线性规划直接对 $P(c|d)$ 进行建模?

假设这个分类任务可以被定义成:

$$Y = \begin{cases} 0 & \text{if No} \\ 1 & \text{if Yes} \end{cases}$$

我们能不能拟合一个线性规划用 X 来预测 Y ，并且根据 $\hat{y} > 0.5$ 来进行分类?

- 因为 $E(Y|X = x) = p(Y = 1|X = x)$ 所以看起还可以。
- 但是线性规划的预测值不是概率。

我们能不能利用线性规划直接对 $P(c|d)$ 进行建模?



假设这个分类任务可以被定义成:

$$Y = \begin{cases} 0 & \text{if No} \\ 1 & \text{if Yes} \end{cases}$$


我们能不能拟合一个线性规划用 X 来预测 Y ，并且根据 $\hat{y} > 0.5$ 来进行分类？

- 因为 $E(Y|X = x) = p(Y = 1|X = x)$ 所以看起还可以。
- 但是线性规划的预测值不是概率。

逻辑函数



逻辑函数 Cont.



$$y = \frac{1}{1 + e^{-x}} = \frac{e^x}{e^x + 1}$$

利用逻辑回归做预测

$$P(Y = 1|X) = \frac{e^{\beta_0 + \beta_1 X}}{e^{\beta_0 + \beta_1 X} + 1}$$

利用逻辑回归做预测

$$P(Y = 1|X) = \frac{e^{\beta_0 + \beta_1 X}}{e^{\beta_0 + \beta_1 X} + 1}$$

$$1 - P(Y = 1|X) = \frac{1}{e^{\beta_0 + \beta_1 X} + 1}$$

这两个等式的比例（odds）是：

$$\frac{P(Y = 1|X)}{1 - P(Y = 1|X)} = e^{\beta_0 + \beta_1 X}$$

利用逻辑回归做预测

$$P(Y = 1|X) = \frac{e^{\beta_0 + \beta_1 X}}{e^{\beta_0 + \beta_1 X} + 1}$$

$$1 - P(Y = 1|X) = \frac{1}{e^{\beta_0 + \beta_1 X} + 1}$$

这两个等式的比例（odds）是：

$$\frac{P(Y = 1|X)}{1 - P(Y = 1|X)} = e^{\beta_0 + \beta_1 X}$$

对其取对数得到logit:

$$\log \left(\frac{P(Y = 1|X)}{1 - P(Y = 1|X)} \right) = \beta_0 + \beta_1 X$$

Overview

基本概念

生成模型

结果评价

判别模型





特征选择

使用大语言模型进行文本分类





熵是评价一个随机变量信息量的方法:

$$H(X) = \sum_{x \in \mathbb{X}} P(x) \log_2 \frac{1}{P(x)} = - \sum_{x \in \mathbb{X}} P(x) \log_2 P(x)$$

哪个事件具有最高的熵?



哪个事件具有最高的熵?



- $H(X_1) = -1 \log 1 = 0$
- $H(X_2) = -0.5 \log 0.5 - 0.5 \log 0.5 = 1$
- $H(X_3) = 4 \times (-0.25 \log 0.25) = 2$
- $H(X_4) = -0.7 \log 0.7 - 3 \times (0.1 \log 0.1) = 1.36$

$$H(X | Y) = \sum_{x,y} P(x, y) \log_2 \frac{1}{P(x | y)} = - \sum_{x,y} P(x, y) \log_2 P(x | y)$$

$$H(X | Y) = \sum_{x,y} P(x, y) \log_2 \frac{1}{P(x | y)} = - \sum_{x,y} P(x, y) \log_2 P(x | y)$$

From the definition:

$$\begin{aligned} H(X | Y) &= \sum_y P(y) H(X | Y = y) \\ &= - \sum_y P(y) \sum_x P(x|y) \log_2 P(x|y) \\ &= - \sum_{x,y} P(y) P(x|y) \log_2 P(x|y) \\ &= - \sum_{x,y} P(x, y) \log_2 P(x|y) \end{aligned}$$

对于两个随机变量 X and Y , 他们的互信息是:

$$\begin{aligned} I(X; Y) &= H(X) - H(X | Y) = H(Y) - H(Y | X) \\ &= \sum_{x \in \mathbb{X}} \sum_{y \in \mathbb{Y}} P(x, y) \log_2 \frac{P(x, y)}{P(x)P(y)} \end{aligned}$$

- 互信息估计了观测到 Y 后 X 的不确定性的变化
- 如果 X 和 Y 互相独立, 则有 $P(x, y) = P(x)P(y)$, 所以 $I(X, Y) = 0$

$$I(X; Y) = \sum_x \sum_y \hat{P}(x, y) \log_2 \frac{\hat{P}(x, y)}{\hat{P}(x) \hat{P}(y)},$$

有:

$$\hat{P}(x, y) = \frac{N_{xy}}{N} \quad \hat{P}(x) = \frac{N_x}{N},$$

N_{xy} 表示 $X = x$ 并且 $Y = y$ 的数量。

$$\begin{aligned} I(X; Y) &= \sum_x \sum_y \frac{N_{xy}}{N} \log_2 \frac{N_{xy}/N}{(N_x/N)(N_y/N)} \\ &= \sum_x \sum_y \frac{N_{xy}}{N} \log_2 \frac{N}{N_x N_y} \end{aligned}$$

文本分类中互信息的计算

定义效用函数 $I(t, c)$ 是词 t 和类别 c 的互信息

$$I(U; C) = \sum_{e_t, e_c \in \{1, 0\}^2} P(U=e_t, C=e_c) \log_2 \frac{P(U=e_t, C=e_c)}{P(U=e_t)P(C=e_c)} \quad (13.16)$$

其中 $e_t = 0$ 表示文本不包含词语 t 。 $e_c = 0$ 表示文本不属于类别 c 。

文本分类中互信息的计算

定义效用函数 $I(t, c)$ 是词 t 和类别 c 的互信息

$$I(U; C) = \sum_{e_t, e_c \in \{1, 0\}^2} P(U=e_t, C=e_c) \log_2 \frac{P(U=e_t, C=e_c)}{P(U=e_t)P(C=e_c)} \quad (13.16)$$

其中 $e_t = 0$ 表示文本不包含词语 t 。 $e_c = 0$ 表示文本不属于类别 c 。

$$\begin{aligned} I(U; C) = & \frac{N_{11}}{N} \log_2 \frac{N N_{11}}{N_{1.} N_{.1}} + \frac{N_{01}}{N} \log_2 \frac{N N_{01}}{N_{0.} N_{.1}} \\ & + \frac{N_{10}}{N} \log_2 \frac{N N_{10}}{N_{1.} N_{.0}} + \frac{N_{00}}{N} \log_2 \frac{N N_{00}}{N_{0.} N_{.0}} \end{aligned}$$

N_{10} 表示包含 t ($e_t = 1$)并且属于 c ($e_c = 0$)的文本。 $N_{0.} = N_{00} + N_{01}$, $N = N_{00} + N_{01} + N_{10} + N_{11}$ 。

互信息计算样例

	$e_c = e_{poultry} = 1$	$e_c = e_{poultry} = 0$
$e_t = e_{export} = 1$	$N_{11} = 49$	$N_{10} = 27,652$
$e_t = e_{export} = 0$	$N_{01} = 141$	$N_{00} = 774,106$

$$\begin{aligned} I(U; C) &= \frac{49}{801,948} \log_2 \frac{801,948 \cdot 49}{(49+27,652)(49+141)} \\ &\quad + \frac{141}{801,948} \log_2 \frac{801,948 \cdot 141}{(141+774,106)(49+141)} \\ &\quad + \frac{27,652}{801,948} \log_2 \frac{801,948 \cdot 27,652}{(49+27,652)(27,652+774,106)} \\ &\quad + \frac{774,106}{801,948} \log_2 \frac{801,948 \cdot 774,106}{(141+774,106)(27,652+774,106)} \\ &\approx 0.000105 \end{aligned}$$

路透社数据集

```
<?xml version="1.0"?>
<REUTERS TOPICS="YES" LEWISSPLIT="TRAIN" CGISPLIT="TRAINING-SET" OLDID="353" NEWID="12125">
  <DATE>1-APR-1987 13:07:30.08</DATE>
  <TOPICS>
    <D>interest</D>
  </TOPICS>
  <PLACES>
    <D>usa</D>
  </PLACES>
  <PEOPLE/>
  <ORGS/>
  <EXCHANGES/>
  <COMPANIES/>
  <UNKNOWN>A
    f1811 reute
r f BC-SUNTRUST-BANKS-&lt;STI&gt; 04-01 0043</UNKNOWN>
  <TEXT>
    <TITLE>SUNTRUST BANKS &lt;STI&gt; RAISES PRIME TO 7-3/4 PCT</TITLE>
    <DATELINE>NEW YORK, April 1 -</DATELINE>
    <BODY>SunTrust Banks said that Sun Banks in
Florida and Trust Co banks in Georgia have raised their prime
rate to 7-3/4 pct from 7-1/2 pct.
    The company said the action is effective immediately.
  </BODY>
  </TEXT>
</REUTERS>
```


路透社数据集上的互信息


Class: coffee

term	MI
<i>coffee</i>	0.0111
<i>bags</i>	0.0042
<i>growers</i>	0.0025
<i>kg</i>	0.0019
<i>colombia</i>	0.0018
<i>brazil</i>	0.0016
<i>export</i>	0.0014
<i>exporters</i>	0.0013
<i>exports</i>	0.0013
<i>crop</i>	0.0012

Class: sports

term	MI
<i>soccer</i>	0.0681
<i>cup</i>	0.0515
<i>match</i>	0.0441
<i>matches</i>	0.0408
<i>played</i>	0.0388
<i>league</i>	0.0386
<i>beat</i>	0.0301
<i>game</i>	0.0299
<i>games</i>	0.0284
<i>team</i>	0.0264

朴素贝叶斯：特征选择的影响



Overview

基本概念


生成模型

结果评价

判别模型

特征选择

使用大语言模型进行文本分类



可以使用Prompt让大语言模型（例如ChatGPT）进行文本分类。

Sentence: I did swap out the hard drive for a Samsung 830 SSD which I highly recommend . What is the sentiment polarity of the aspect hard drive in this sentence?

Sentiment polarity: negative

Given a review, extract the aspect term(s) and determine their corresponding sentiment polarity. Review: I can say that I am fully satisfied with the performance that the computer has supplied .

Aspect terms: computer performance

Sentiment polarity: positive

少样本学习

Sentence: The keyboard is too slick . What is the sentiment polarity of the aspect keyboard in this sentence?

Label: negative

Sentence: Decent wine at reasonable prices . What is the sentiment polarity of the aspect wine in this sentence?

Label: positive

Sentence: Amazing Quality ! What is the sentiment polarity of the aspect Quality in this sentence?


Label: positive

Sentence: I did swap out the hard drive for a Samsung 830 SSD which I highly recommend . What is the sentiment polarity of the aspect hard drive in this sentence?

Label: neutral

角色扮演

You are an expert at sentiment analysis. Given a text by the user, analyze the sentiment of the text if it is 'positive' or 'negative'.



➤ Traditional Prompting

-  Given the sentence "The new mobile phone can be just put in my pocket.", what is the sentiment polarity towards **the new mobile phone**?
-  The sentiment polarity of the given sentence is **neutral**. The sentence simply states that the new mobile phone can be put in the speaker's pocket and does not express any positive or negative sentiment towards the phone.

➤ Three-hop Reasoning with CoT Prompting

- 1st-hop: Inferring aspect**
-  Given the sentence "The new mobile phone can be just put in my pocket.", which specific aspect of the new mobile phone is possibly mentioned?
 -  The specific aspect of the new mobile phone mentioned in the sentence is **the size or portability**. → Appending to the next context
- 2nd-hop: Inferring opinion**
-  Given the sentence, "The new mobile phone can be just put in my pocket.", the specific aspect of the new mobile phone mentioned in the sentence is the size or portability. Based on the common sense, what is the implicit opinion towards the mentioned aspect of the new mobile phone, and why?
 -  Based on the mentioned aspect of size and portability, the sentence implies that the phone is small enough to fit in the speaker's pocket. According to common sense, the implicit opinion of speaker towards the portability is **good**, because the speaker is able to easily carry the phone with them by placing it in their pocket, and find the phone to be **convenient and easy to use**. → Appending to the next context
- 3rd-hop: Inferring polarity**
-  Given the sentence, "The new mobile phone can be just put in my pocket.", the specific aspect of the new mobile phone mentioned in the sentence is the size or portability. Based on the mentioned aspect of size and portability, the sentence implies that the phone is small enough to fit in the speaker's pocket. According to common sense, the implicit opinion of speaker towards the portability is good, because the speaker can easily carry the phone with them by placing it in their pocket, and find the phone to be convenient and easy to use. Based on such opinion, what is the sentiment polarity towards the new mobile phone?
 -  The sentiment polarity towards the new mobile phone based on the given sentence is **positive**. The speaker finds the phone to be convenient and easy to use, implying having a favorable view of the phone.

Questions?