

IMDB情感分类 (30%)

陈冠毅

g.chen@ccnu.edu.cn

计算机学院
华中师范大学

Overview

实验内容

实验报告

答辩

时间线

实验基本情况

- 使用IMDB数据集进行文本分类（二分类）
- 数据分析和预处理
- 构建模型（产生式系统、朴素贝叶斯、逻辑回归、特征选择、大语言模型）
- 结果分析
- 实验报告（第16周）
- 实验答辩（第14-15周）
- 三人一组完成实验

- 训练集、开发集和测试集分别有多大我？
- 训练集中有多少正向情感和负向情感的句子？
- 训练集中每种情感中频率前十的词都有什么？ PMI前十大的词都有什么？
- 训练集中的用词有什么特点？ 都是什么词性？ 他们表达任何情感信息吗？
- ...

数据预处理

- 停用词
- 标点符号
- 词元
- ...

模型构建

1. 产生式系统

- 设计能够进行情感分类的规则
- 利用NLTK、WordNet、SentiWordNet等工具包

2. 朴素贝叶斯、逻辑回归

- 使用词频作为特征训练朴素贝叶斯模型和逻辑回归模型进行情感分类
- 利用SKlearn工具包

3. 特征选择

- 对使用词频作为特征的逻辑回归模型进行特征选择（例如，最好的前200、2000个特征），至少完成两个不同的特征选择结果所训练的模型。
- 在逻辑回归模型基础上，设计至少两个新的特征，并训练一个新的模型。

4. 大语言模型:

- 至少使用一种Prompt设计策略在一种大语言模型上测试至少200条测试集中的数据。
- 设计prompt使大语言模型产生结构化输出，包含更多的信息。例如，每条数据谈论了什么主题，谈论这个主题是表现了什么情感？输出结果用框架表示法表示。测试至少20条测试集中的数据。

结果分析

1. 使用上课学习的评测指标对上述至少6个模型（除大语言模型之外）在测试集上进行测试；
2. 使用可视化方法比较上述7个模型（除大语言模型结构化输出之外）的性能；
3. 使用SentiWordNet分析除了产生式系统之外的所有模型的输出结果。例如，包含正向情感词数量和预测成为正向情感的相关程度。
4. 观察大语言模型的结构化输出，用语言总结你的发现。

Overview

实验内容

实验报告

答辩

时间线

实验报告结构

1. 引言：定义任务及其意义
2. 实验数据
 - 2.1 数据描述
 - 2.2 数据预处理
3. 基于规则的情感分析模型(描述你的模型，并且阐述你为什么这样设计模型)
4. 基于机器学习的情感分析模型(需要包括对于新设计特征的描述以及原因)
5. 基于大语言模型的情感分析模型
6. 实验结果和分析
7. 结论
8. 附录

实验报告要求

1. 实验报告使用DeepSeek（辅助）撰写。附录中包含如何使用大语言模型辅助撰写报告的详细说明。
2. 长度不超过8页。
3. 非必要不要贴代码、不要截图。

Overview

实验内容

实验报告

答辩

时间线

答辩要求

- 时长：10分钟演讲+ 5分钟问题
- 你做了什么？（主要展示你与众不同的地方，例如，特征选择、特征设计、**Prompt**设计、框架式表示设计等）
- 你有什么发现？（数据、模型等）

Overview

实验内容

实验报告

答辩

时间线

时间线

1. 第9周：介绍实验内容，开始实验
2. 第10周：五一放假
3. 第11周：进行实验
4. 第12周：期中考试（?）
5. 第13周：进行实验
6. 第14周：答辩
7. 第15周：答辩
8. 第16周：提交实验报告和代码

Questions?